

研究計画書

実環境への導入に向けた討論型マルチ LLM 意思決定の低遅延化

研究背景・これまでの成果

GPU 資源配分では、利用者が多くの GPU を求める需要側の目的と、利用率・公平性・将来需要を守る供給側の目的が対立する。また、保守、障害、ジョブ間の依存関係など、数値だけでは表せない例外への対応も必要である。これまでの研究では、需要側 LLM と供給側 LLM の主張を審判 LLM が統合する討論方式を構築した。文章による例外を含む 81 件の合成事例では、実行可能かつ正しい判断が、同じ推論回数の単一 LLM 多数決方式の 29 件に対し、討論方式では 43 件となり、相互検討による信頼性向上の可能性を確認した。

一方、三つの LLM を用いる討論は応答が遅く、全ての配分判断に適用することは難しい。また、実際の運用テキストで同じ効果が得られるかは未検証である。そのため、修士課程では、**討論による信頼性を維持しながら推論遅延を削減し、実環境で利用可能な方式へ発展させることを課題とする。**

研究目的

本研究の目的は、**どの入力に、どのモデルを、何段階まで用いれば、最小の遅延で信頼できる判断を得られるかを明らかにすることである。**通常時は高速な市場方式または単一 LLM を使い、文章による例外、低い確信度、エージェント間の不一致がある場合のみ討論を起動する適応的な方式を開発する。最終的には、精度と遅延のトレードオフを定量化し、実環境へ段階的に導入できるプロトタイプを構築する。

研究方法

まず、入力処理、各 LLM の生成、検証、待ち時間を計測し、討論方式の遅延要因を明らかにする。次に、需要側と供給側の並列実行、短い構造化出力、小型・大型モデルの切替え、早期終了、キャッシュを導入する。数値だけで処理できる入力には決定論的な市場方式を用い、例外情報がある場合だけ LLM を起動する。討論型に加え、入札、価格、投票などの軽量な市場戦略も比較する。LLM の出力は決定論的検証器で確認し、制約違反やタイムアウト時には市場方式へ戻す。

最終的に、資源状態と運用テキストを受け取り、配分案、根拠、信頼度、検証結果を返す API を実装する。初めは既存スケジューラを直接制御しないシャドーモードで安全性と応答時間を評価し、確認後に実システムとの連携を進める。

評価方法

現在の常時討論方式、単一 LLM、多数決、市場方式、提案方式を同じモデル・ハードウェア条件で比較する。既存の 81 件に加え、可能であれば匿名化した実運用テキストを用いる。正解率、制約充足率、SLA 違反率に加え、平均・95 パーセンタイル遅延、スループット、トークン数、討論起動率、フォールバック率を測定する。目標は、常時討論に近い信頼性を保ちながら、通常時には市場方式に近い応答速度を得ることである。

修士課程における研究計画

修士 1 年次には遅延計測基盤と評価データを整備し、各高速化手法および市場戦略を比較する。修士 2 年次には選択した方式を API へ統合し、再生環境とシャドーモードで評価した後、成果を論文および修士論文としてまとめる。これにより、自然言語による例外処理の信頼性を保ちながら、実環境へ安全に導入できる低遅延な LLM 意思決定基盤の実現を目指す。