

# 研究計画書

## 予測不確実性と説明可能な AI エージェントを用いた 高性能計算環境の GPU 資源スケジューリング

### 研究背景と課題

生成 AI や科学技術計算の発展により、GPU を共有する高性能計算（HPC）環境の需要が急増している。一方、利用者が申請した GPU 数と実際の使用量には差が生じやすく、過剰申請による資源の遊休や、過少申請・待ち時間の増加による処理遅延が問題となる。さらに、ジョブの実行時間や資源需要は投入時点では正確に分からず、限られた GPU を効率よく利用しながら、期限の厳しいジョブを保護することは難しい。

近年は大規模言語モデル（LLM）を資源管理へ応用する研究も進んでいるが、LLM は数値計算や制約充足を誤る可能性があり、推論時間と運用コストも大きい。また、投入スクリプトに既に記載された情報と、自然言語にのみ含まれる例外情報を区別せず LLM へ与えると、従来手法で処理できる通常の判断まで不安定になり得る。したがって本研究の課題は、**予測の不確実性、期限の切迫度、資源制約を決定論的に扱いつつ、構造化されていない運用情報が必要な場合に限り LLM を安全に利用することである。**

### 提案手法

本研究では、予測情報に基づく GPU スケジューリング方式 PINS（Prediction-Informed Negotiated Scheduling）を提案する。まず、ジョブの実行時間、GPU 使用率およびメモリ需要を分位点回帰により予測し、点予測だけでなく予測区間として不確実性を表現する。次に、各時刻における残り時間、残り計算量および期限から正規化余裕度（laxity）を再計算し、期限が迫るジョブの優先度を動的に高める。GPU 配分は入札・提示価格に基づく決定論的な市場機構で決定し、多次元のノード配置には整数計画法を用いて、容量制約と実行可能性を保証する。

LLM は通常の配分処理には使用せず、保守予定、外部締切、ジョブ間依存、取消し、再実行不能など、数値状態に含まれない自然言語の例外情報が検出された場合にのみ呼び出す。LLM は自由形式の割当てではなく、限定された候補から修正理由と構造化された提案を出力し、最終的な適用可否は決定論的検証器が判断する。すなわち、**LLM は状況を解釈して説明し、プログラムが配分を決定して安全性を保証する構成とする。**

### 評価と評価結果

Alibaba GPU Cluster Trace を用いたシミュレーションにより、実トレース由来のジョブ属性を持つ 96 ジョブ、8 GPU、32 シードの条件で評価した。固定された投入時優先度を用いる方式と、各時刻に期限余裕度を更新する提案方式を、同一のジョブ列で対応比較した。本研究で得られた最も顕著な結果は、**動的優先度により SLA 違反率が 23.8% から 7.4% へ 16.4 ポイント減少し、平均スローダウンも 17.82 から 5.35 へ低下したことである。**SLA 差の 95% 信頼区間は  $16.4 \pm 3.1$  ポイントであり、複数の期限設定に対して同じ改善方向を確認した。一方、GPU 利用率の差は 1.7 ポイントにとどまり、95% 信頼区間はゼロを含んだ。この結果は、単に GPU を多く使用するのではなく、現在の期限余裕度に応じて配分順序を更新することが、待ち時間と期限違反の抑制に有効であることを示す。

### 今後の予定

今後は、第一に、動的期限優先度、予測不確実性、市場機構および整数計画配置を統合し、FIFO、EASY Backfilling などの古典的方式と同一条件で比較する。第二に、自然言語にのみ含まれる保守予定や依存関係などを加えた文脈イベント付き再生環境を構築し、LLM を用いない方式、選択的 LLM 方式および正解情報を与えるオラクル方式を比較する。第三に、LLM を呼び出す判定と、呼び出し後の提案内容を分離して評価し、誤介入率、見逃し率、推論時間およびトークンコストを測定する。最終的には、通常時の高速性と決定論的安全性を維持しながら、例外的な運用情報だけを説明可能に処理できる GPU 資源管理方式を確立する。