

研究計画書

実環境への導入に向けた討論型マルチ LLM 意思決定の低遅延化

研究背景とこれまでの成果

生成 AI の普及により GPU 需要が増加し、限られた資源を高い利用率で公平に分配することが重要となっている。従来の強化学習による配分は、判断過程がブラックボックスとなりやすく、障害、保守、ジョブ間の依存関係などの例外に対して運用者が原因を確認し、方針を修正することが難しい。大規模言語モデル（LLM）は自然言語による説明と柔軟な例外処理が可能である一方、単一 LLM に需要側と供給側の相反する目的を同時に判断させると、重要な観点や制約を見落とす可能性がある。

これまでの研究では、LLM を「できるだけ早く多くの GPU を確保したい需要側」と「クラスタ全体の利用率、公平性、将来需要を守りたい供給側」に分け、両者の主張を審判 LLM が統合する討論型の資源配分方式を構築した。保守・障害通知、依存関係、取消し、運用方針上の例外などを付加した 81 件の合成事例で、同じ推論回数の単一 LLM 多数決方式と比較した結果、実行可能かつ正しい判断は単一 LLM 方式の 29 件に対し、討論方式では 43 件であった。この結果から、複数の観点から相互検討する構造が、自然言語による例外判断の信頼性を改善する可能性が示された。

しかし、需要側、供給側、審判を順に実行する討論方式は、単一 LLM や数値的な市場方式より応答が遅く、全ての配分判断に適用すると実運用の妨げとなる。また、現在の結果は合成テキストに基づいており、実際の運用情報でも効果を保てるかは未検証である。したがって、修士課程では討論方式をさらに複雑化するのではなく、得られた信頼性向上を維持しながら、どこまで推論遅延を削減できるかを中心課題とする。

研究目的

本研究の目的は、討論型マルチ LLM の判断精度と説明可能性を維持しつつ、実サービスの時間制約内で動作する低遅延な意思決定方式を確立することである。中心となる研究課題は、「どの入力に、どのモデルを、何段階まで用いれば、最小の遅延で信頼できる判断を得られるか」である。

具体的には、(1) 現在の需要・供給・審判方式の遅延を分解し、主要なボトルネックを明らかにする。(2) 通常の判断には高速な市場方式または単一 LLM を用い、文章による例外や判断の不一致がある場合だけ討論へ切り替える適応的な方式を開発する。(3) 精度と遅延のトレードオフを定量化し、実環境へ段階的に導入できるプロトタイプとして実装する。

研究方法

1. 討論処理の遅延分析現在の方式について、入力処理、最初のトークンが出るまでの時間、需要側・供給側の生成時間、審判の生成時間、検証時間、待ち行列時間を個別に計測する。入力長、出力長、モデル規模、討論回数、同時要求数を変え、平均値だけでなく 95・99 パーセンタイル遅延とスループットを測定する。これにより、モデル計算、逐次的な処理、長い説明文のうち、どの要因が実運用上の遅延を支配するかを明らかにする。

2. 信頼性を維持する適応的低遅延化高速化手法を個別および組合せで検証する。第一に、需要側と供給側の初期判断を並列化する。第二に、出力を短い構造化形式へ限定し、判断に不要な文章生成を削減する。第三に、小型モデルで一次判断を行い、確信度が低い、制約違反の可能性がある、またはエージェント間で結論が一致しない場合のみ大型モデルや審判へ処理を送る。第四に、類似状態の結果を再利用するキャッシュと、結論が安定した時点で討論を終了する早期終了を導入する。

さらに、数値情報だけで処理できる通常時は決定論的な市場方式を高速経路とし、保守通知や取消しなどの文章情報を含む場合のみ LLM 経路を起動する。討論型に加えて、入札、価格、投票などゲーム理論・市場戦略に基づく軽量の意見統合も比較し、正解率と遅延の Pareto 最適な方式を選ぶ。全ての LLM 出力は決定論的検証器で容量制約や規則への適合を確認し、タイムアウトまたは違反時には市場方式へ戻すことで、低遅延化が安全性の低下につながらないようにする。

3. 実用プロトタイプの構築資源配分状態と運用テキストを入力し、配分案、短い根拠、信頼度、検証結果を返す API を実装する。各要求には応答期限を設定し、期限内に LLM 判断が完了しない場合は高速経路の結果を返す。遅延、モデル選択、討論回数、フォールバック理由を記録し、運用者が判断過程と性能を確認できる画面を用意する。

初期段階では既存スケジューラを直接制御せず、実際の入力に対して提案だけを生成するシャドーモードで評価する。記録された実判断と提案を比較して安全性を確認した後、許可された範囲でスケジューラとの連携を進める。この段階的な構成により、研究用の実験から実環境で利用可能な製品へ移行する。

評価計画

評価では、現在の需要・供給・審判方式を精度上限の基準とし、単一 LLM、多数決、決定論的市場方式、および提案する適応的低遅延方式を同じモデル・ハードウェア条件で比較する。データには既存の 81 件の合成事例を用いるとともに、公開データを調査し、可能であれば許可と匿名化を前提として実際の障害・保守通知、依存関係、取消し等を含む運用テキストを収集する。

信頼性指標は、正解率、制約充足率、同一・類似入力に対する一貫性、SLA 違反率とする。実用性能指標は、エンドツーエンドの平均・95・99 パーセンタイル遅延、最初のトークンまでの時間、スループット、トークン数、討論起動率、早期終了率、フォールバック率とする。各高速化要素を除いたアブレーション実験を行い、どの要素が精度を保ちながら遅延を削減したかを特定する。最終的には、常時討論方式に近い信頼性を維持しながら、通常時には市場方式に近い応答速度を実現できるかを検証する。

修士課程における研究計画

修士 1 年次前半には、既存方式を再現し、詳細な遅延計測基盤と実テキストを含む評価データを整備する。後半には、並列化、構造化短文出力、小型・大型モデルの経路選択、早期終了、キャッシュを実装し、精度・遅延曲線を比較する。また、討論型と市場戦略型の統合方式を同一条件で評価し、プロトタイプに採用する構成を決定する。

修士 2 年次前半には、選択した方式を API と運用者向け画面へ統合し、同時要求、タイムアウト、モデル障害を含む条件で性能と安全性を評価する。実環境またはクラストラースの再生環境でシャドウモード評価を行い、運用に必要な応答時間と信頼性を満たす条件を明らかにする。後半には結果を整理し、システムの限界と適用条件を明示した上で、研究成果を論文および修士論文としてまとめる。

期待される成果

本研究により、討論型マルチ LLM の遅延がどこで発生し、どの入力にどの程度の討論が必要かを定量的に説明できる。さらに、単一の高速化技術ではなく、入力の難しさに応じて市場方式、単一 LLM、マルチ LLM 討論を使い分ける設計により、信頼性と応答速度の両立を目指す。最終成果として、例外的な自然言語情報を扱えるという LLM の利点を保ちながら、既存システムへ安全かつ段階的に導入できる低遅延な意思決定支援基盤を提示する。