

研究計画書

Auction と討論型マルチ LLM を組み合わせた GPU 資源配分

提案手法

本研究では、投入されたジョブを、運用上のテキスト情報の有無によって二つの経路に分ける。備考、障害・保守通知、依存関係、取消し、特別な優先指示などのテキストがないジョブは **auction** で処理する。一方、このようなテキストがあるジョブだけを討論型マルチ LLM で処理する。これにより、通常の数値情報だけで判断できる多数のジョブでは LLM を起動せず、推論時間と計算費用を削減する。

1. テキストのないジョブを処理する auction

Auction は、各ジョブが追加の GPU をどの程度必要としているかを入札値で表し、クラスタ側が GPU を提供するための価格を提示して、両者が一致する範囲まで資源を配分する決定論的な仕組みである。自然言語の生成を行わず、数値計算だけで結果を決めるため、高速であり、同じ入力には常に同じ結果を返す。

まず、各ジョブは 1 台目、2 台目、3 台目というように、追加 GPU ごとの限界価値を入札する。入札値には、その GPU によって増える有効な処理量、期限に遅れる危険性、待機時間、および実行中のジョブを拡大・縮小する費用を反映する。一般に GPU を追加するほど得られる効果は小さくなるため、各ジョブの入札値は GPU 台数の増加に伴って低下する曲線とする。これにより、単に要求台数が多いジョブではなく、追加 GPU から大きな効果を得られるジョブが優先される。

次に、供給側は、クラスタの空き GPU 数、現在の混雑度、資源の断片化、待機中ジョブ数、および今後到着する重要ジョブの可能性から、1 台ごとの売値を計算する。多くの GPU を配分して残りが少なくなるほど売値を高くすることで、資源を一つのジョブへ過剰に配分せず、将来の需要に備える。

市場を清算する際には、全ジョブの入札値を高い順に並べ、供給側の売値と比較する。 q 台目について入札値が売値以上であれば、その GPU を該当ジョブへ配分する。入札値が売値を下回った時点で配分を終了する。すなわち、

$$Q = \max\{q \mid b_{(q)} \geq a_q\}$$

として配分台数 Q を決定する。ここで $b_{(q)}$ は高い順に並べた q 番目の入札値、 a_q は q 台目の売値である。同じ値の場合の順序もあらかじめ固定し、結果を再現可能にする。さらに、現在の配分から GPU を移動する利益がジョブの縮小・再配置費用を上回る場合だけ変更を適用し、頻繁な配分変更を防止する。最後に、総配分数が容量を超えていないか、負の配分や未知のジョブがないかを決定論的に検証する。

2. テキストのあるジョブを処理する討論型マルチ LLM

テキストが付与されたジョブでは、数値だけでは例外の意味を判断できないため、需要側 LLM、供給側 LLM、審判 LLM を起動する。需要側 LLM は、期限、依存関係、取消し、障害の影響などからジョブが GPU を必要とする理由を述べる。供給側 LLM は、クラスタ全体の容量、公平性、他ジョブへの影響、保守上の制約から反対意見または修正案を示す。両者は互いの主張を確認して再判断し、審判 LLM が auction による通常ジョブの配分と残り容量も考慮して最終案を決定する。

最後に、auction の結果と討論の結果を統合し、全ジョブの総配分がクラスタ容量を超えないことを検証する。討論結果が制約に違反した場合、または制限時間内に得られなかった場合は、そのジョブの数値情報を用いた auction の結果へ戻す。この構成により、通常ジョブは auction で高速に処理し、自然言語による例外判断が必要なジョブだけに LLM の推論能力を用いる。