

研究計画書

需要・供給 LLM 協調と選択的起動による 高性能計算環境の GPU 資源スケジューリング

研究背景と課題

生成 AI や科学技術計算の発展により、GPU を共有する高性能計算（HPC）環境の需要が急増している。限られた GPU を多数のジョブへ配分する際には、利用者側の要求（短い待ち時間、期限達成、必要資源の確保）と、運用者側の要求（高い利用率、公平性、将来ジョブのための余力確保）を同時に考慮する必要がある。このような複数目的の判断に大規模言語モデル（LLM）の推論能力を利用する研究が進んでいるが、単一の LLM へ相反する目的を同時に与えるだけで十分なのかは明らかでない。

一方、LLM による判断は従来の決定論的手法より遅く、複数エージェントによる議論は推論時間と計算コストをさらに増加させる。そのため、全てのスケジューリング判断で LLM を起動する方式は実運用に適さない。本研究の目的は、次の二つの問いに答えることである。(1) 需要側と供給側の役割を分けた LLM 間の交渉は、単一 LLM による判断を改善するか。(2) 推論時間の大きい LLM を、どのような状況で起動すべきか。

提案手法

本研究では、予測情報に基づく GPU スケジューリング方式 PINS（Prediction-Informed Negotiated Scheduling）を提案する。需要側 LLM は、各ジョブの緊急性、期限および資源要求を基に追加 GPU の必要性を主張する。供給側 LLM は、クラスタ全体の利用率、公平性、空き資源および将来需要の観点からその主張を検討する。両者は回数を制限した交渉を行い、その結果を構造化された提案として出力する。この需要・供給方式を、同じ情報と同等の推論予算を与えた単一 LLM 方式と比較することで、性能差が単なる推論量ではなく、役割分担と相互検討によるものかを検証する。

通常時は高速な市場機構を用い、判断が難しい場合のみ LLM 交渉へ処理を切り替えるゲートを設ける。候補となる起動条件は、長時間待機、期限切迫、資源競合、通常の数値状態では表せない運用情報、および高速方式の判断に対する低い確信度である。起動しない場合は市場機構の結果をそのまま用い、起動した場合も LLM の出力を決定論的検証器で確認し、容量制約を満たさない提案は適用しない。これにより、交渉の効果と推論コストの均衡点を求める。

評価と評価結果

需要・供給交渉の効果を調べるため、通常の数値情報だけでは判断できない 81 件の GPU 配分事例を用い、同一事例に対する対応比較を行った。需要側と供給側が最初の提案を相互に読み、反論後に再判断する方式と、同じ回数だけ単一 LLM を呼び出して多数決を取る方式を比較した。実行可能かつ正しい判断が得られた事例は、単一 LLM 方式の 29/81 件に対し、**需要・供給交渉方式では 43/81 件**であった。対応のある正確検定では $p = 0.00066$ となり、単に LLM の呼出し回数を増やすだけでなく、異なる観点を相互に検討する構造が判断改善に寄与する可能性が示された。ただし、この結果は判断事例上の評価であり、クラスタ全体の性能向上と起動コストについては、実トレース再生による追加検証が必要である。

今後の予定

今後は、第一に、需要・供給の目的が異なる交渉方式と、両者が同じ目的を持つ対称的な複数 LLM 方式を比較し、改善が対立する役割によるものか、単なる二回目の検討によるものかを明らかにする。第二に、Alibaba GPU Cluster Trace を用いた再生実験へ選択的起動ゲートを統合し、待ち時間、期限切迫度、競合度などの起動条件を個別に比較する。第三に、単一 LLM、常時交渉、選択的交渉および LLM を使用しない高速方式について、SLA 違反率、ジョブ完了時間、GPU 利用率、起動率、推論時間およびトークン数を評価する。最終的には、単一 LLM を上回るために需要・供給交渉が必要となる条件と、その効果が推論コストを上回る起動条件を明確にし、実運用可能な LLM 支援型 GPU スケジューラを確立する。